UNIVERSIDAD INTERNACIONAL DEL ECUADOR

Maestría en Ciencia de Datos y Máquinas de Aprendizaje con mención en Inteligencia Artificial

Proyecto Sistema de Análisis Predictivo o de clasificación

Informe

Predicción de la Formalidad Laboral en Ecuador mediante Algoritmos de Machine Learning (ENEMDU 2025)

Autor

Saúl Fernando Mendieta Tenesaca

HOJA DE CONTENIDOS

1. **Resumen ejecutivo** **3**
2. **Introducción y Contexto** **3**
3. **Marco Teórico y Conceptual** **4**
   - 3.1. Definición de Formalidad e Informalidad Laboral: 4
   - 3.2. Enfoque Estructural del Empleo: 5
   - 3.3. Fundamentos de Aprendizaje Automático (Machine Learning) 6
     - 3.3.1. Modelos Paramétricos: Regresión Logística 7
     - 3.3.2. Modelos No Paramétricos de Ensamble: Random Forest y Gradient Boosting 7
4. **Arquitectura de Datos y Metodología (Data Engineering)** **8**
   - 4.1. Fuente de Datos y Alcance Poblacional 8
   - 4.2. Proceso ETL (Extracción, Transformación y Limpieza) 9
   - 4.3. Integración en Base de Datos Relacional (SQLite) 9
   - 4.4. Definición de Variables y Criterio de Muestreo 9
   - 4.5. Omisión del Factor de Expansión (fexp) - Justificación Metodológica 10
   - 4.6. Criterios de Ética, Privacidad y Uso Responsable de Datos e IA 11
5. **Análisis Exploratorio de Datos (EDA) y Hallazgos Descriptivos** **11**
   - 5.1. Distribución global: 12
   - 5.2. Factores demográficos 12
   - 5.3. Análisis de sexo (p02), área urbana/rural (area) y estado civil (p06). 14
   - 5.4. Capital Humano: Impacto del Nivel Educativo en la Tasa de Formalidad 14
   - 5.5. Estructura productiva: 15
6. **Modelado Predictivo (Machine Learning)** **18**
   - 6.1. Preprocesamiento y partición de datos 18
   - 6.2. Ingeniería de características y Transformación Matricial 19
   - 6.3. Algoritmos de Clasificación Seleccionados y Configuración Técnica 20
7. **Evaluación de Resultados** **22**
   - 7.1. Métricas de Desempeño Comparativas 22
   - 7.2. Matrices de Confusión y Evaluación de Tipos de Error 23
   - 7.3. Selección del Modelo Óptimo: Justificación Técnica 24
8. **Conclusiones y Factores Determinantes** **25**
   - 8.1. Importancia de Variables: Análisis del Top 15 de Factores Determinantes 25
   - 8.2. Hallazgos Económicos y Estructurales: La Primacía de la Matriz Productiva y el Capital Humano 27
   - 8.3. Reflexión Metodológica: El Valor de Integrar SQL y Machine Learning en la Investigación Económica 27
9. **Bibliografía** **28**
10. **Repositorio de código:** **29**

1. Resumen ejecutivo

El presente estudio aplicado tiene como objetivo principal el clasificar y predecir la condición de formalidad laboral en el mercado ecuatoriano, utilizando los microdatos de la Encuesta Nacional de Empleo, Desempleo y Subempleo (ENEMDU) del año 2025. La investigación se limita estrictamente a la población económicamente activa (PEA) que en encuentre ocupada. Es decir, el universo engloba a aquellas personas igual o mayores a 15 años de edad, que hayan realizado alguna actividad económica en la semana de referencia, logrando consolidar una muestra analítica de 154,330 observaciones, que se encuentran filtradas con 10 variables utilizadas como predictoras.

A nivel metodológico, el flujo de trabajo integra técnicas de Data Engineering, utilizando una base de datos relacional en SQLite, con el fin de asegurar la integridad de la extracción de datos. Además, el análisis continúa con un análisis exploratorio de datos "EDA", y finalmente, se realiza el entrenamiento de tres algoritmos de Machine Learning supervisado que corresponden a: Regresión Logística, Random Forest y Gradient Boosting.

Para determinar el modelo que mejor se ajusta y predice, la base de datos debió ser dividida en 80% aprendizaje y 20% pruebas. Tras el análisis de los resultados obtenidos, se determinó que el modelo de Gradient Boosting alcanzó la mayor exactitud predictiva con un 87% de aciertos y con un ROC-AUC de 0.9450. Posteriormente, el análisis de importancia de variables (Feature Importance) reveló que la formalidad en Ecuador responde principalmente a factores estructurales del mercado (pertenencia al sector privado corporativo y empresas de 100 o más trabajadores) y de capital humano (educación superior), relegando a un impacto menor a las variables puramente demográficas.

2. Introducción y Contexto

La informalidad laboral constituye uno de los desafíos estructurales más persistentes en América Latina y en el mercado de trabajo ecuatoriano. Lejos de ser un fenómeno coyuntural, la coexistencia de un sector empresarial moderno junto a un amplio segmento de unidades productivas de subsistencia genera profundas asimetrías en la productividad, la cobertura de seguridad social y los ingresos de los hogares. Comprender qué factores determinan la inserción formal de un trabajador resulta indispensable para que el diseño políticas públicas sean realmente útiles.

Tradicionalmente, los determinantes de la formalidad laboral se han analizado mediante modelos econométricos lineales. Aunque estos métodos ofrecen una base interpretativa valiosa, enfrentan limitaciones para capturar relaciones no lineales e interacciones complejas entre múltiples variables sociodemográficas, educativas y productivas en grandes volúmenes de microdatos. Frente a ello, las integraciones de Ingeniería de Datos con algoritmos de Aprendizaje Automático Supervisado permiten modelar la estructura ocupacional del país con mayor poder predictivo y granularidad analítica.

El objetivo de este informe es desarrollar y evaluar un sistema de clasificación binaria que prediga la formalidad laboral en el Ecuador e identifique la jerarquía de sus factores determinantes, empleando los microdatos oficiales de la encuesta ENEMDU 2025 del Instituto Nacional de Estadística y Censos (INEC). El estudio delimita su alcance a la Población Económicamente Activa (PEA) ocupada de 15 años o más, consolidando una matriz depurada de 154.330 observaciones y 10 variables predictoras.

El documento se estructura de forma secuencial, donde primero se expone el marco teórico sobre informalidad laboral (OIT, CEPAL e INEC) y los fundamentos de los algoritmos empleados; segundo, se detalla la arquitectura de datos en Python, SQLite y ética de datos. Posteriormente, se desarrolla el Análisis Exploratorio de Datos y la evaluación comparativa de tres clasificadores (Regresión Logística, Random Forest y Gradient Boosting) sobre el conjunto de prueba (n = 30.866). Finalmente, a partir del determinar el mejor modelo (Gradient Boosting, con 87,00% de exactitud y ROC-AUC de 0,9450), se analiza la importancia de las variables para extraer conclusiones sobre el peso de la estructura empresarial y el capital humano.

3. Marco Teórico y Conceptual

El modelado predictivo del mercado laboral exige articular la teoría económica del empleo con el aprendizaje estadístico. Por ello, este capítulo expone las bases conceptuales que sustentan la selección de variables y el diseño algorítmico del estudio: primero, se define la formalidad e informalidad laboral bajo los estándares de la OIT y del INEC; segundo, se examina el enfoque de heterogeneidad estructural y capital humano; y, finalmente, se describen los algoritmos de clasificación supervisada implementados.

3.1. Definición de Formalidad e Informalidad Laboral:

El estudio de la estructura del mercado de trabajo requiere establecer una distinción conceptual entre la formalidad y la informalidad laboral. A nivel mundial, la Organización Internacional del Trabajo (OIT) establece el marco normativo de referencia más aceptado y utilizado. En su Recomendación sobre la transición de la economía informal a la economía formal (núm. 204), la OIT define el fenómeno desde la perspectiva de la cobertura legal e institucional de las actividades productivas, estableciendo textualmente que la economía informal abarca "todas las actividades económicas desarrolladas por los trabajadores y las unidades económicas que —en la legislación o en la práctica— están insuficientemente cubiertas por sistemas formales o no lo están en absoluto". (Organización Internacional del Trabajo, 2021)

Este enfoque conceptual distingue dos dimensiones analíticas complementarias: el sector informal desde el enfoque o caracterización de la unidad productiva o empresa y el empleo informal enfocado en las condiciones del puesto de trabajo, tales como el acceso a la seguridad social y los beneficios de ley. En este sentido, la formalización no solo implica el registro tributario o legal de las unidades económicas, sino también la protección efectiva del trabajador. Como señala el organismo internacional: "Integrar a los trabajadores dentro del sistema legal e institucional, asegurar el cumplimiento de las leyes y regulaciones (...) es un imperativo para acceder al trabajo decente". (Organización Internacional del Trabajo, Teoría del cambio: Formalización empresarial para el trabajo decente, 2021, pág. 5)

Para el caso específico del Ecuador, el Instituto Nacional de Estadística y Censos (INEC) operacionaliza estas directrices internacionales dentro de la Encuesta Nacional de Empleo, Desempleo y Subempleo (ENEMDU) a partir de la actualización metodológica implementada en junio de 2015 y los ajustes a la metodología realizados en el año 2021.

Para clasificar a la población ocupada, el INEC utiliza como criterio discriminante principal la tenencia del Registro Único de Contribuyentes (RUC) y la escala del establecimiento productivo. Oficialmente, el ente estadístico ecuatoriano define estas categorías bajo los siguientes términos: "Población con empleo en el sector informal: Personas con empleo que trabajan en empresas que no tienen Registro Único de Contribuyentes" (Instituto Nacional de Estadísticas y Censos, 2015, pág. 4). En contrapartida, el sector formal agrupa a las personas con empleo que laboran en establecimientos de 100 o más trabajadores, o en unidades productivas de menor tamaño que se encuentran legalmente constituidas y cuentan con RUC registrado ante la administración tributaria.

Paralelamente a la naturaleza formal o informal del establecimiento, la metodología de la ENEMDU evalúa la calidad de la inserción laboral a través de la condición de actividad, destacando la categoría de empleo adecuado o pleno, la cual se vincula estrechamente con la estabilidad del sector formal y el cumplimiento de garantías laborales. El INEC define esta condición de la siguiente manera: "Empleo adecuado/pleno: personas con empleo que, durante la semana de referencia, perciben ingresos laborales iguales o superiores al salario mínimo, trabajan igual o más de 40 horas a la semana, independientemente del deseo y disponibilidad de trabajar horas adicionales". (INEC, 2025, pág. 7)

Por consiguiente, la dualidad entre formalidad e informalidad en los microdatos de la ENEMDU 2025 utilizados en este estudio refleja tanto la capacidad del tejido empresarial ecuatoriano para operar dentro del marco tributario y societario (RUC y tamaño de empresa), como la garantía de condiciones laborales estables asociadas a la jornada legal, el acceso a la seguridad social y la modalidad contractual.

3.2. Enfoque Estructural del Empleo:

Para comprender que determina la formalidad laboral desde una perspectiva económica, la literatura especializada en América Latina aborda el mercado de trabajo a partir del concepto de heterogeneidad estructural. Esta concepción fue desarrollada originalmente por la escuela estructuralista de la Comisión Económica para América Latina y el Caribe (CEPAL), y su enfoque sostiene que en las economías en desarrollo o de tercer mundo, coexisten estratos productivos modernos de alta eficiencia junto con un amplio segmento de unidades económicas rezagadas, cuyas marcadas brechas de productividad (ineficiencias) se trasladan directamente a las condiciones laborales de los trabajadores.

En este sentido, la CEPAL ha señalado que la desigualdad en el acceso a empleos formales y protegidos no es un fenómeno aleatorio, sino que responde a la configuración misma del aparato productivo. Como lo expone Abramo en el marco analítico de la CEPAL, la estructura socioeconómica de la región está asentada en "una matriz productiva altamente heterogénea que está en la base de un acceso muy estratificado al empleo de calidad y a la protección social y de una alta desigualdad de ingresos en los hogares". (Abramo, 2021, pág. 3)

Dentro de la matriz productiva, el tamaño de la empresa y la categoría de ocupación operan como los principales canales de transmisión de la formalidad laboral. Las empresas de mayor envergadura (100 o más trabajadores) y las corporaciones privadas estructuradas cuentan con economías de escala, acceso a financiamiento e intensidad tecnológica suficiente para absorber los costos laborales asociados a la seguridad social y a la contratación legal. En contraste, los pequeños negocios y el autoempleo presentan severos límites operativos y financieros que dificultan su transición hacia la formalidad.

Por otro lado, al analizar la distribución de la ocupación urbana en América Latina, (Tokman, 2007) afirma que "los asalariados constituyen en promedio alrededor del 63,5 por ciento de la ocupación urbana. Dos tercios de ellos están ocupados en empresas privadas formales y en el sector público, mientras que el tercio restante está en microempresas informales y en el servicio doméstico" (pág. 5)

De manera complementaria a los factores de demanda productiva (tamaño y tipo de establecimiento), el lado de la oferta laboral está determinado por la dotación de capital humano, siendo el nivel de instrucción educativa una de sus variables fundamentales. Los estratos productivos modernos y formales demandan mano de obra calificada capaz de operar procesos técnicos, administrativos y científicos complejos, siendo el nivel de estudio de los individuos una barrera de entrada importante para aquella fuerza laboral con menor escolaridad.

Por consiguiente, la educación actúa como un mecanismo diferenciador en la inserción ocupacional, tal es así que, (Borrastero, Viganó, & Gómez, 2022) afirman que al examinar la interrelación entre heterogeneidad estructural, calificaciones e informalidad, "p*or un lado, los trabajadores empleados en el mercado laboral informal están, por lo general, menos calificados que los trabajadores registrados, lo que se traduce en grandes diferencias salariales. Al mismo tiempo, los trabajadores con menor nivel educativo son más propensos a desempeñarse en empleos informales que los trabajadores más calificados, y también tienen mayor probabilidad que estos últimos de transitar de la formalidad a la informalidad"* (pág. 9).

En síntesis, la calidad del empleo en economías como la ecuatoriana está determinada por la intersección de dos fuerzas estructurales: la capacidad productiva del establecimiento empleador (medida a través del tamaño de la empresa y la categoría ocupacional privada o pública) y el nivel de cualificación del individuo (medido a través de la educación formal alcanzada). Esta base teórica sustenta la inclusión de dichas variables como predictores centrales dentro de los modelos de aprendizaje automático desarrollados en el presente estudio.

3.3. Fundamentos de Aprendizaje Automático (Machine Learning)

El Aprendizaje Automático o Machine Learning, constituye una rama de la inteligencia artificial cuyo propósito es desarrollar técnicas computacionales que permitan a los sistemas identificar patrones complejos en grandes volúmenes de información. Como señalan (Mendoza, Macías, Morales, &

Cedeño, 2024) "Mediante el uso de algoritmos y modelos matemáticos, el Aprendizaje Automático *permite a las máquinas aprender de los datos sin ser programadas explícitamente" (pág. 90).*

Dentro de esta disciplina, el presente estudio se enmarca en el paradigma del aprendizaje supervisado, específicamente en la tarea de clasificación binaria. Este enfoque opera a partir de una matriz de datos históricos previamente etiquetados, donde el algoritmo aprende la relación matemática entre un conjunto de variables explicativas (X) y una variable objetivo dicotómica (Y), con el fin de asignar una etiqueta o categoría a nuevas instancias basadas en sus características predefinidas (Mendoza Álava et al., 2024).

En la modelación predictiva sobre microdatos socioeconómicos, la literatura distingue dos grandes familias algorítmicas: los modelos paramétricos (lineales) y los modelos no paramétricos basados en ensambles de árboles de decisión. La implementación conjunta de ambos enfoques en esta investigación responde a la necesidad metodológica de contrastar la simplicidad e interpretabilidad estadística frente a la potencia predictiva no lineal.

3.3.1. Modelos Paramétricos: Regresión Logística

Los modelos paramétricos asumen una estructura funcional predefinida entre las variables predictores (independientes) y la variable de respuesta (dependiente). El estándar de referencia (baseline) para problemas de clasificación dicotómica es la Regresión Logística, según los investigadores del INEC, (Valdiviezo & Aguiar, 2026), su funcionamiento se define bajo los siguientes términos: "la regresión logística modela la probabilidad de ocurrencia de un evento binario a partir de una combinación lineal de variables predictoras. Esta probabilidad se transforma en intervalo [0,1] mediante la función logística o sigmoide, lo que permite interpretar la salida del modelo como la probabilidad de pertenecer a una de las dos clases" (p. 14).

Si bien la Regresión Logística ofrece una alta trazabilidad sobre el peso individual de cada regresor, su supuesto de linealidad en los parámetros limita su capacidad para detectar interacciones complejas entre múltiples variables categóricas y continuas.

3.3.2. Modelos No Paramétricos de Ensamble: Random Forest y Gradient Boosting

Para superar las restricciones de los modelos lineales, los métodos no paramétricos basados en árboles de decisión dividen el espacio de características de manera recursiva sin asumir una distribución probabilística previa. Con el objetivo de evitar el sobreajuste propio de un árbol individual, las técnicas de ensamble combinan múltiples árboles débiles para consolidar un clasificador robusto, destacando dos arquitecturas principales: Bagging y Boosting.

Por un lado, el algoritmo Random Forest (Bosque Aleatorio) implementa la técnica de ensamblado en paralelo (bagging). Tal como describe (Portilla Cartuche, 2026) en su investigación aplicada, en donde afirma que "en Random Forest se construyen algunos árboles de decisión entrenados sobre subconjuntos de los datos aleatorios, lo que permite la reducción de la varianza" (pág. 6). Es así que,

al promediar las predicciones de cientos de árboles independientes que evalúan subconjuntos aleatorios de variables, el modelo neutraliza el ruido muestral y estabiliza la clasificación.

Por otro lado, los algoritmos basados en Gradient Boosting (potenciación del Gradiente) aplican una arquitectura de ensamblado secuencial (boosting). Es decir, en lugar de entrenar árboles de forma independiente, cada nuevo árbol se construye para corregir los residuos o errores de clasificación cometidos por los árboles predecesores. Al describir la mecánica matemática de esta familia de algoritmos, (Valdiviezo & Aguiar, 2026) destacan que, "a diferencia de enfoques lineales, este método optimiza de forma iterativa una función de pérdida mediante gradiente descendente, lo que le permite capturar relaciones no lineales y efectos de interacción entre predictores" (pág. 15).

En consecuencia, la evaluación comparativa entre Regresión Logística, Random Forest y Gradient Boosting permite determinar empíricamente hasta qué punto la formalidad laboral en Ecuador obedece a una suma lineal de factores o a una red de interacciones no lineales entre la estructura empresarial y el capital humano.

4. Arquitectura de Datos y Metodología (Data Engineering)

El desarrollo de modelos de aprendizaje automático exige una arquitectura de ingeniería de datos (Data Engineering) que garantice la calidad, integridad, trazabilidad y reproducibilidad de la información desde su estado crudo (original) hasta la matriz analítica final. Para el presente estudio, se diseñó e implementó un flujo de trabajo secuencial en lenguaje Python, utilizando la plataforma de Google Colab, estructurado en cuatro etapas metodológicas.

4.1. Fuente de Datos y Alcance Poblacional

La fuente primaria de información corresponde a los microdatos oficiales de la Encuesta Nacional de Empleo, Desempleo y Subempleo (ENEMDU) del año 2025, generada por el Instituto Nacional de Estadística y Censos (INEC). La encuesta recopila información socioeconómica a nivel de hogares e individuos en todo el territorio nacional.

Dado que el objetivo del estudio se centra exclusivamente en clasificar la condición de formalidad dentro del mercado de trabajo activo, se delimitó el alcance poblacional aplicando dos filtros estructurales alineados con la metodología oficial del INEC:

a) Criterio de edad laboral: Se seleccionó únicamente a los individuos con edad igual o superior a los 15 años ($p03 \geq 15\ a\tilde{n}os$), umbral que define a la Población en Edad de Trabajar (PET) en el Ecuador, según el INEC.
b) Condición de ocupación: Utilizando la variable oficial precalculada por el INEC de condición de actividad (condact), se filtró a la población económicamente inactiva y a los desempleados, conservando estrictamente a los individuos pertenecientes a la Población Económicamente Activa (PEA) que registraron una condición de ocupados durante la semana de referencia.

Tras la aplicación de estos criterios de inclusión y la depuración de registros inconsistentes, el universo analítico se consolidó en una muestra final de 154,330 observaciones válidas.

4.2. Proceso ETL (Extracción, Transformación y Limpieza)

Los archivos originales de microdatos suelen presentar desafíos técnicos asociados a la codificación de caracteres, formatos mixtos y valores perdidos. El proceso de Extracción, Transformación y Carga (ETL) se ejecutó mediante la biblioteca pandas, abarcando las siguientes operaciones de depuración:

a) Estandarización de tipos de datos: En las bases crudas de encuestas de hogares, los valores vacíos o no aplicables suelen representarse como cadenas de texto con espacios en blanco (" "). Se implementó una rutina de conversión forzada a formato numérico (pd.to_numeric), transformando cualquier carácter no numérico en valores nulos explícitos (NaN).
b) Tratamiento de valores perdidos (Missing Values): Para evitar distorsiones artificiales derivadas de la imputación sintética en variables categóricas sensibles (como la rama de actividad o el grupo ocupacional), se aplicó una eliminación por lista (listwise deletion) sobre las observaciones con datos faltantes en los predictores seleccionados, asegurando que los 154,330 registros finales cuenten con información completa y verificada.
c) Aseguramiento de dominios: Se verificó que todas las categorías numéricas de las variables seleccionadas correspondieran estrictamente a los rangos establecidos en el diccionario de variables del INEC 2025.

4.3. Integración en Base de Datos Relacional (SQLite)

Una práctica fundamental en los flujos de Ciencia de Datos es desacoplar la etapa de limpieza de archivos planos (.csv) de la etapa de modelado matemático. Operar directamente sobre archivos de texto en cada iteración analítica incrementa el consumo de memoria RAM y expone el proyecto a modificaciones accidentales de los datos limpios.

Para solventar esto, la matriz depurada en el proceso ETL fue ingestada en un motor de base de datos relacional ligero mediante SQLite, generando el archivo persistente enemdu_2025.db y consolidando la tabla maestra denominada empleo_formalidad.

La extracción posterior hacia el entorno de análisis exploratorio y entrenamiento algorítmico se efectuó exclusivamente mediante consultas en Lenguaje de Consulta Estructurado (SQL). Esta arquitectura híbrida (Python + SQL) asegura la inmutabilidad de la fuente limpia (base original), y optimiza los tiempos de lectura en la nube (Google Colab), dotando al proyecto de un estándar de ingeniería reproducible en entornos productivos.

4.4. Definición de Variables y Criterio de Muestreo

El modelo predictivo se estructura a partir de una variable dependiente dicotómica (Y) y diez variables independientes o predictoras (X) que capturan las dimensiones demográficas, educativas y productivas del trabajador.

- Variable Objetivo (target_formal): Para evitar sesgos en la construcción manual de indicadores, la variable dependiente se generó directamente a partir de la clasificación oficial de sectorización laboral precalculada por el INEC en la ENEMDU (la cual segmenta a los ocupados en Sector Formal, Sector Informal, Empleo Doméstico y No Clasificados). A partir de este clasificador oficial, se binarizó la variable objetivo asignando el valor 1 (Formal) exclusivamente a los trabajadores clasificados dentro del sector formal, y el valor 0 (Informal / No Formal) a aquellos ubicados en el sector informal, servicio doméstico o no clasificados.
- Variables Predictoras (*X*): Se seleccionaron 10 variables características sociodemográficas y ocupacionales, excluyendo de la matriz predictora las variables precalculadas de resultado (secemp, condact) o preguntas filtro directas como la tenencia de RUC (p49), con el fin de evitar tautologías estadísticas o fuga de datos hacia el algoritmo.

Tabla 1: Variables utilizadas y criterios de muestreo

Código INEC	Nombre de la Variable	Naturaleza	Escala / Categorías Principales	Dimensión Analítica
p02	Sexo	Categórica Binaria	1: Hombre, 2: Mujer	Demográfica
p03	Edad	Numérica Continua	15 a 98 años	Demográfica
area	Área Geográfica	Categórica Binaria	1: Urbana, 2: Rural	Territorial
p06	Estado Civil	Categórica Nominal	1: Casado, 2: Separado, 3: Divorciado, 4: Viudo, 5: Unión libre, 6: Soltero	Demográfica
nnivins	Nivel de Instrucción	Categórica Ordinal	1: Ninguno, 2: Alfabetización, 3: Básica, 4: Bachillerato, 5: Superior	Capital Humano
p24	Horas de Trabajo	Numérica Continua	Horas semanales efectivas trabajadas	Estructura Laboral
p42	Categoría de Ocupación	Categórica Nominal	1: Empleado gobierno, 2: Empleado privado, 3: Tercerizado, 4: Jornalero, 5: Patrono, 6: Cuenta propia, 7–10: Otros/No remunerados	Estructura Productiva
p47a	Tamaño del Establecimiento	Categórica Binaria	1: Menos de 100 trabajadores, 2: 100 y más trabajadores	Estructura Productiva
rama1	Rama de Actividad (CIIU)	Categórica Nominal	21 secciones económicas (Agricultura, Manufactura, Comercio, Enseñanza, etc.)	Estructura Productiva
grupo1	Grupo Ocupacional (CIUO)	Categórica Nominal	10 grandes grupos (Directores, Profesionales, Técnicos, Operadores, Trabajadores no calificados, etc.)	Estructura Laboral

Elaborado por: el autor.

4.5. Omisión del Factor de Expansión (fexp) - Justificación Metodológica

En las publicaciones de estadística descriptiva oficial, el INEC utiliza el factor de expansión (fexp) como un ponderador muestral para extrapolar los resultados de la encuesta hacia el total poblacional

macroeconómico del Ecuador. Sin embargo, en el presente estudio de Machine Learning, se determinó metodológicamente operar sobre la muestra no ponderada (n = 154,330).

Esta decisión se fundamenta en la literatura econométrica y de aprendizaje estadístico, es así que (Solon, Haider, & Wooldridge, 2013), establecen que cuando el propósito del modelado es estimar relaciones estructurales condicionales y aprender límites de decisión a nivel microanalítico —en lugar de contabilizar totales poblacionales—, el uso de ponderadores muéstrales basados en conglomerados geográficos puede inflar artificialmente la varianza de los estimadores y sesgar la función de pérdida de los algoritmos de clasificación hacia observaciones específicas con pesos extremos.

Al entrenar los modelos directamente sobre los 154,330 registros observados bajo el supuesto de observaciones independientes, se garantiza que los algoritmos asignen la importancia de las variables en función de los atributos reales del individuo y no de su ponderación geográfica muestral.

4.6. Criterios de Ética, Privacidad y Uso Responsable de Datos e IA

En estricto apego a los principios de gobernanza de datos y uso ético de la Inteligencia Artificial, el diseño y ejecución del presente sistema de clasificación incorporó tres salvaguardas fundamentales a lo largo de todo el ciclo de vida de los datos:

a) Privacidad, Anonimización y Secreto Estadístico: Los microdatos de la ENEMDU 2025 utilizados en este estudio provienen de fuentes abiertas oficiales del INEC y cumplen con el principio de secreto estadístico establecido en la Ley de Estadística del Ecuador. Durante la fase de extracción (ETL) e ingesta en la base de datos relacional (enemdu_2025.db), se excluyeron identificadores directos o cuasi-identificadores de vivienda, hogar o directorio (id_vivienda, id_hogar, id_persona), operando exclusivamente sobre vectores de atributos agregables que impiden cualquier proceso de re-identificación individual de los 154.330 encuestados.
b) Mitigación de Sesgos Algorítmicos y Equidad (Fairness): Un riesgo ético recurrente en los sistemas de clasificación socioeconómica es que los algoritmos reproduzcan o amplifiquen sesgos históricos de discriminación por razones de género o estado civil. Como se verifica empíricamente en la evaluación de importancia de variables, la inclusión de controles estructurales objetivos -tales como el nivel de instrucción educativa (nnivins), el tamaño del establecimiento (p47a) y la categoría ocupacional (p42)- permite que el modelo asigne un peso marginal cercano a cero a las variables demográficas sensibles como el sexo (p02), garantizando predicciones basadas en la estructura productiva y no en estereotipos demográficos.
c) Transparencia, Explicabilidad y No Maleficencia: Frente a la opacidad de los modelos de "caja negra", se implementaron métricas auditables de desagregación de errores (Matrices de Confusión para monitorear Falsos Positivos y Falsos Negativos) y extracción de importancia de características.

5. Análisis Exploratorio de Datos (EDA) y Hallazgos Descriptivos

Previo al entrenamiento de los algoritmos de clasificación, se ejecutó un Análisis Exploratorio de Datos (EDA) sobre las 154,330 observaciones que conforman la muestra limpia. El propósito de esta etapa es

examinar la distribución empírica de la variable objetivo (target_formal) y describir las frecuencias relativas de formalidad e informalidad a través de las diez variables predictoras seleccionadas. Cabe reiterar que las cifras presentadas a continuación reflejan el comportamiento directo de las observaciones muestrales (sin factor de expansión), constituyendo la línea base exacta sobre la cual aprenden los modelos matemáticos.

5.1. Distribución global:

El análisis univariado de la variable dependiente target_formal revela una distribución equilibrada entre ambas categorías dentro de la muestra analítica. Del total de 154,330 personas ocupadas de 15 años o más, el 54.14% se encuentra clasificado dentro del sector formal (target_formal = 1), mientras que el 45.86% restante pertenece al sector informal o categorías no formales (target_formal = 0).

1. Disitribución global empleo por sectores



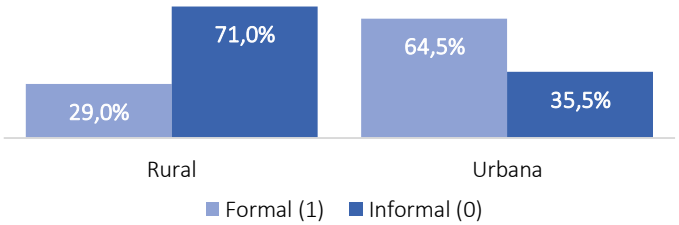
Fuente: INEC, Enemdu 2025 - Elaboración propia.

Desde la perspectiva técnica del aprendizaje automático, esta proporción (cercana a una relación 54/46) representa un escenario de clases balanceadas. Esto implica que los algoritmos de clasificación cuentan con suficiente volumen de información representativa para ambos grupos, eliminando la necesidad de aplicar técnicas artificiales de sobremuestreo (como SMOTE) o submuestreo, las cuales podrían alterar la varianza natural de los datos originales.

5.2. Factores demográficos

Al cruzar la condición de formalidad con las características sociodemográficas y geográficas del individuo, se observan patrones diferenciados en la estructura de la muestra analizada. En primer lugar, la segmentación por área geográfica (area) evidencia un contraste marcado según la ubicación territorial del trabajador. En el sector urbano (area = 1), la proporción de empleo formal es mayoritaria y supera el 64% de los ocupados residentes en ciudades, mientras que en el área rural (area = 2) la distribución se invierte de manera pronunciada, concentrando la mayor parte de la fuerza laboral en actividades de carácter informal (71%).

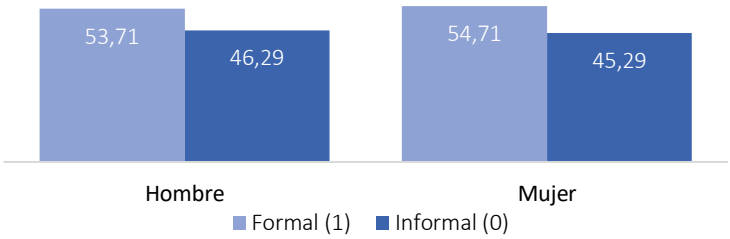
2. Distribución del sector de empleo por área



Fuente: INEC, Enemdu 2025 - Elaboración propia.

Por su parte, el análisis por sexo (p02) permite distinguir entre el volumen absoluto de participación y la proporción relativa de formalidad dentro de cada grupo. Si bien los hombres (p02 = 1) representan un mayor número total de ocupados en la muestra (87,686 hombres frente a 66,644 mujeres), al evaluar la distribución interna de cada sexo se observa que las mujeres registran una proporción de formalidad ligeramente superior a la de los hombres. Específicamente, del total de mujeres ocupadas, el 54.71% se ubica en el sector formal y el 45.29% en el informal; mientras que, dentro del total de hombres ocupados, el 53.71% pertenece al sector formal y el 46.29% se encuentra en la informalidad. Esta cercanía porcentual entre ambos grupos explica por qué la variable sexo no figura entre los predictores principales en los modelos posteriores.

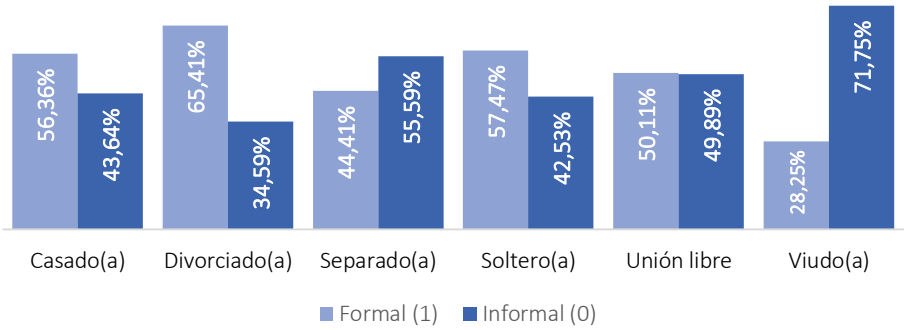
3. Distribución del sector de empleo por sexo



Fuente: INEC, Enemdu 2025 - Elaboración propia.

Esta caracterización demográfica se complementa con el comportamiento del estado civil (p06), donde se registran variaciones en la proporción de formalidad según la categoría conyugal. Los porcentajes más elevados de inserción formal dentro de cada grupo corresponden a las personas divorciadas (p06 = 3) con un 65.41% (4,637 de 7,089), seguidas por las personas solteras (p06 = 6) con un 57.47% (27,955 de 48,647) y las personas casadas (p06 = 1) con un 56.36% (29,507 de 52,358).

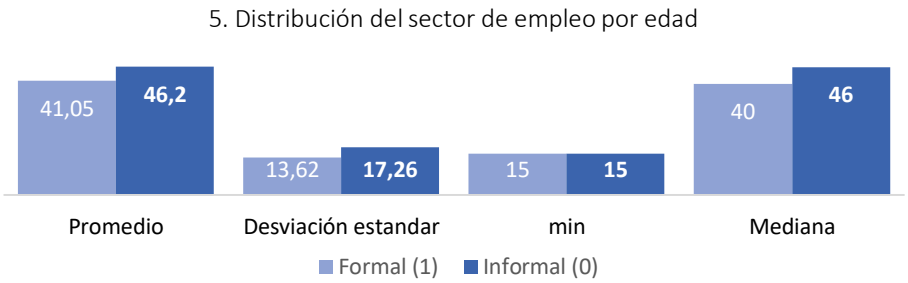
4. Distribución del sector de empleo por estado civil



Fuente: INEC, Enemdu 2025 - Elaboración propia.

En una posición intermedia se ubican quienes mantienen unión libre (p06 = 5), presentando una distribución paritaria de 50.11% en la formalidad y 49.89% en la informalidad (sobre 30,571 individuos). En el extremo opuesto, la informalidad predomina en las personas separadas (p06 = 2) con un 55.59% (5,896 de 10,606) y alcanza su mayor concentración en las personas viudas (p06 = 4), donde el 71.75% (3,630 de 5,059) trabaja en condiciones informales.

5.3. Análisis de sexo (p02), área urbana/rural (area) y estado civil (p06).



Fuente: INEC, Enemdu 2025 - Elaboración propia.

Finalmente, el examen de la edad (p03) como variable numérica continua muestra diferencias en la tendencia central y dispersión de ambos sectores. Los trabajadores del sector formal presentan una edad promedio de 41.05 años (desviación estándar de 13.62 años y mediana de 40 años), concentrando el 50% central de su población (rango intercuartílico) entre los 30 y 51 años. Por el contrario, los trabajadores del sector informal registran una edad media superior, ubicada en 46.20 años (mediana de 46 años), acompañada de una mayor dispersión (desviación estándar de 17.26 años y rango intercuartílico entre 32 y 59 años), lo que refleja una mayor permanencia de adultos mayores en actividades informales.

5.4. Capital Humano: Impacto del Nivel Educativo en la Tasa de Formalidad

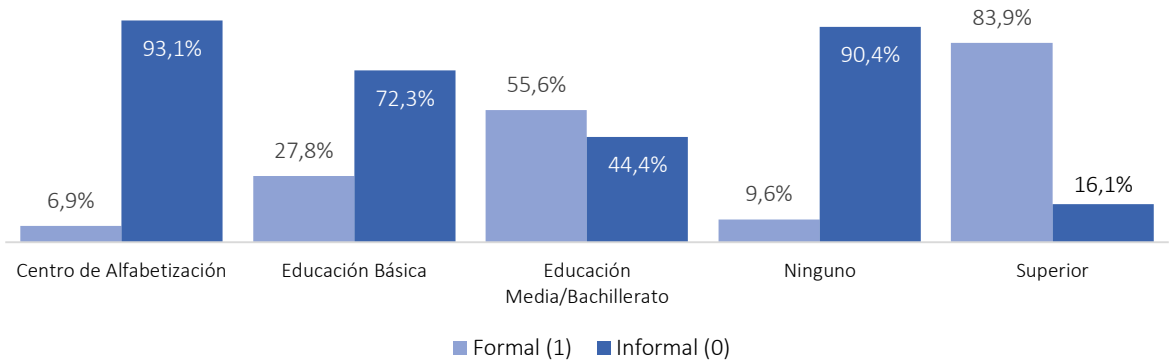
La evaluación de la variable de nivel de instrucción (nnivins) evidencia una relación directa, monotónica y creciente entre el grado de escolaridad formal alcanzado por el trabajador y su probabilidad de inserción en el sector formal en el mercado laboral ecuatoriano. A medida que se asciende en la escala educativa, la proporción de informalidad disminuye de forma sistemática, confirmando el rol del capital humano como una barrera de protección frente a la precariedad laboral.

En los niveles iniciales de instrucción, el mercado de trabajo muestra un predominio casi absoluto de la informalidad. Específicamente, dentro del grupo de personas sin ningún nivel educativo (nnivins = 1, con un total de 3,261 ocupados), el 90.43% (2,949 personas) desempeña sus actividades en el sector informal y apenas el 9.57% (312 personas) accede a la formalidad. Un comportamiento aún más pronunciado se observa en quienes provienen de centros de alfabetización (nnivins = 2, con 277 registros), donde el 93.14% (258 trabajadores) se ubica en la informalidad frente a un reducido 6.86% (19 trabajadores) en el sector formal.

Al avanzar hacia el segmento de Educación Básica (nnivins = 3), el cual constituye uno de los bloques poblacionales más numerosos de la muestra con 49,713 ocupados, la restricción de acceso al empleo formal persiste de manera marcada. En esta categoría, el 72.25% de los individuos (35,920 personas) trabaja en condiciones de informalidad, mientras que únicamente el 27.75% (13,793 personas) logra insertarse en unidades productivas formales. En términos de composición global, los trabajadores con

educación básica representan por sí solos más de la mitad (50.75%) de toda la fuerza laboral informal de la muestra analizada.

6. Sector de empleo por nivel de instrucción



Fuente: INEC, Enemdu 2025 - Elaboración propia.

El punto de inflexión estadístico se registra al alcanzar la Educación Media o Bachillerato (nnivins = 4), categoría que agrupa el mayor volumen absoluto de ocupados en el estudio con 54,324 observaciones. En este estrato educativo la tendencia se revierte por primera vez, logrando que la formalidad supere a la informalidad: el 55.61% de los bachilleres (30,211 personas) cuenta con un empleo en el sector formal, frente a un 44.39% (24,113 personas) que permanece en el sector informal.

Finalmente, el salto estructural definitivo se consolida en el grupo con Educación Superior (nnivins = 5), conformado por 46,755 profesionales y técnicos ocupados. Dentro de este segmento de alta cualificación, la tasa de formalidad asciende drásticamente hasta el 83.89% (39,222 trabajadores), relegando la informalidad a tan solo el 16.11% (7,533 trabajadores). Asimismo, al observar la estructura interna del empleo formal total en el país (83,557 personas), se constata que el 46.94% de todos los empleos formales están ocupados por individuos con títulos de educación superior, seguido por un 36.16% de bachilleres, lo que demuestra empíricamente que las unidades productivas formales absorben de manera preferente a la mano de obra con mayor dotación de capital humano.

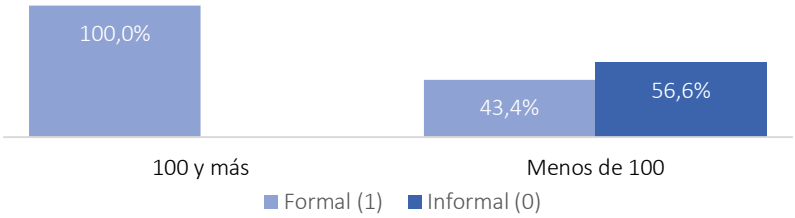
5.5. Estructura productiva:

Las variables vinculadas a la escala del establecimiento económico, la modalidad de inserción laboral y la estructura sectorial presentan las segmentaciones más determinantes de todo el conjunto de datos analizado (n = 154,330). A diferencia de los factores demográficos, donde las proporciones tienden a equilibrarse, el examen de la estructura productiva revela fronteras claramente demarcadas entre la formalidad y la informalidad.

En primer término, la evaluación del tamaño del establecimiento (p47a) evidencia una polarización absoluta según la escala operativa de la unidad productiva. En las empresas de 100 y más trabajadores (p47a = 2), que agrupan a 29,320 ocupados de la muestra, la tasa de formalidad alcanza el 100.00%, aportando por sí solas el 35.09% de todo el empleo formal del estudio. En marcado contraste, los establecimientos de menos de 100 trabajadores (p47a = 1, con 125,010 ocupados) concentran el 100.00%

de la fuerza laboral informal del país (70,773 personas); dentro de este segmento de micro, pequeñas y medianas unidades, el 56.61% opera en la informalidad y el 43.39% (54,237 personas) logra insertarse en el sector formal.

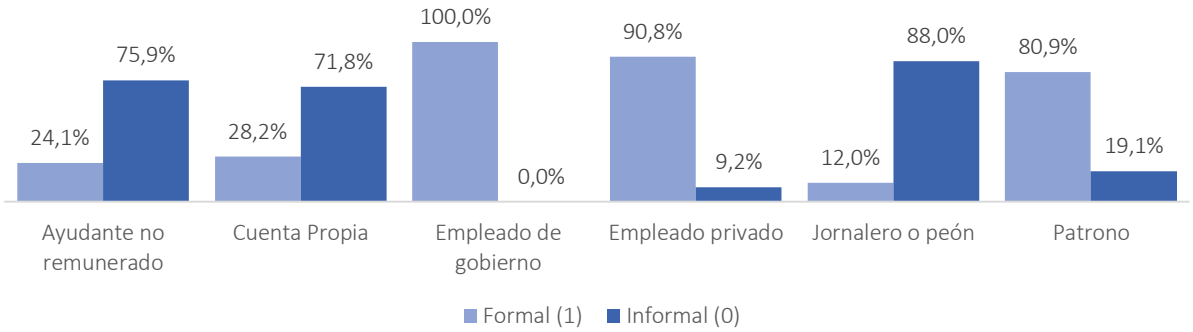
7. Sector de empleo por tamaño del establecimiento



Fuente: INEC, Enemdu 2025 - Elaboración propia.

De manera concordante, el análisis de la categoría de ocupación (p42) demuestra que las relaciones salariales institucionalizadas constituyen el núcleo de la formalidad. Específicamente, los empleados de gobierno (p42 = 1, con 14,908 registros) registran un 100.00% de formalidad, mientras que los empleados privados (p42 = 2, con 46,528 ocupados) alcanzan una tasa de formalidad del 90.81% (42,250 formales frente a solo 4,278 informales), consolidándose como la categoría individual de mayor peso al aportar el 50.56% de todos los empleos formales de la muestra. Una tendencia favorable similar exhibe los patronos (p42 = 5), con un 80.89% de formalidad (3,860 de 4,772).

8. Sector de empleo por categoría de ocupación



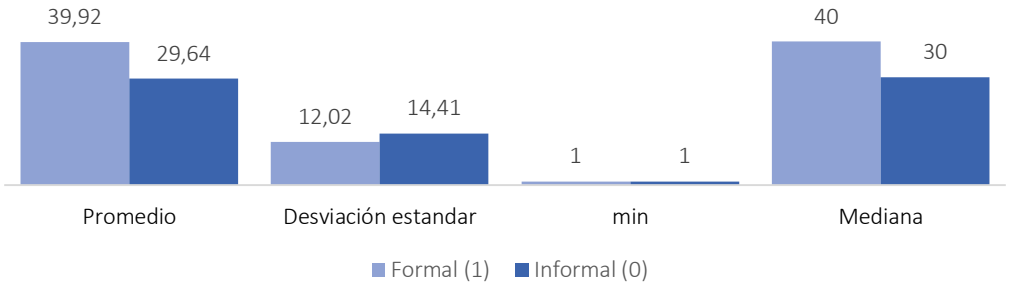
Fuente: INEC, Enemdu 2025 - Elaboración propia.

En el extremo opuesto, la informalidad predomina de forma severa en las modalidades de autoempleo y trabajo precario: los trabajadores por cuenta propia (p42 = 6, la categoría más numerosa de la muestra con 57,492 personas) presentan un 71.76% de informalidad (41,254 individuos, lo que representa el 58.29% del total de informales del estudio). Esta condición se agudiza aún más en los jornaleros o peones (p42 = 4), donde la informalidad asciende al 88% (12,483 de 14,185), y en los trabajadores del hogar no remunerados (p42 = 7), con un 72.05% de informalidad (11,574 de 16,064).

Por su parte, la distribución de las horas semanales trabajadas (p24) refleja con exactitud las diferencias en la estabilidad de la jornada laboral entre ambos sectores. Los trabajadores del sector formal registran un promedio de 39.92 horas semanales (desviación estándar de 12.02 horas) y una estructura

altamente compacta: tanto el primer cuartil (25%) como la mediana (50%) se ubican exactamente en las 40.00 horas, y el tercer cuartil (75%) en 44.00 horas, lo que confirma el cumplimiento estricto de la jornada legal estándar. Por el contrario, los trabajadores informales presentan un promedio sustancialmente inferior de 29.64 horas semanales y una elevada dispersión (desviación estándar de 14.41 horas), con su primer cuartil en 20.00 horas, una mediana de 30.00 horas y el tercer cuartil en 40.00 horas, evidenciando una alta incidencia de subempleo por insuficiencia de tiempo de trabajo.

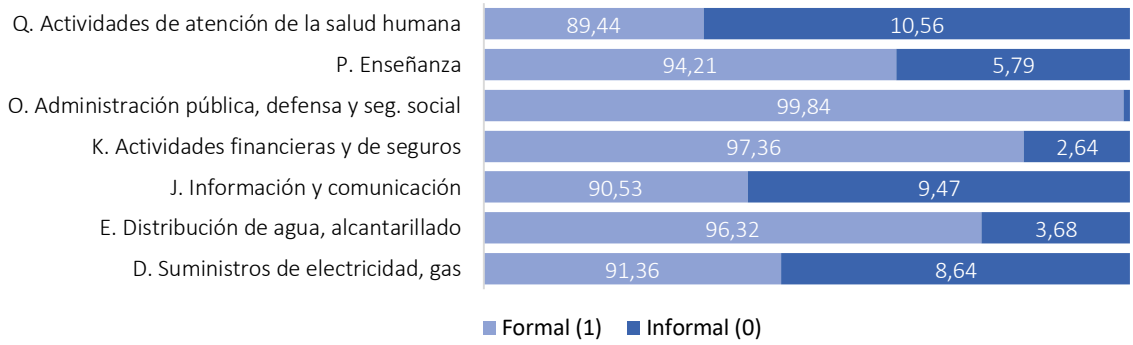
9. Sector de empleo por horas semanales



Fuente: INEC, Enemdu 2025 - Elaboración propia.

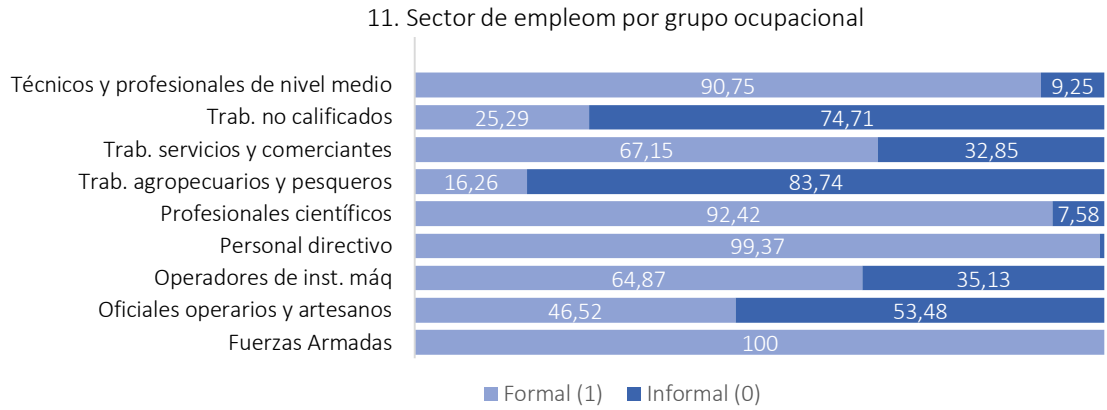
Finalmente, la desagregación por rama de actividad económica (rama1) y grupo ocupacional (grupo1) confirma la heterogeneidad estructural del aparato productivo ecuatoriano. A nivel sectorial, la formalidad es hegemónica en ramas altamente institucionalizadas o intensivas en capital, tales como Administración pública y defensa (99.84%), Actividades financieras y de seguros (97.36%), Distribución de agua y alcantarillado (96.32%), Enseñanza (94.21%), Suministro de electricidad y gas (91.36%), Información y comunicación (90.53%) y Atención de la salud humana (89.44%).

10. Sectores de empleo por rama de actividad



Fuente: INEC, Enemdu 2025 - Elaboración propia.

En una franja intermedia-alta destacan Industrias manufactureras (69.71% de formalidad sobre 16,315 ocupados) y Comercio y reparación de vehículos (62.68% de formalidad sobre 29,993 ocupados). En contrapartida, la informalidad se concentra de manera crítica en la Agricultura, ganadería, silvicultura y pesca (rama1 = A), donde el 84.80% de sus 36,941 trabajadores es informal (aportando por sí sola el 44.26% de toda la informalidad nacional), seguida por la Construcción (rama1 = F), con un 74.72% de informalidad (6,745 de 9,027).



Fuente: INEC, Enemdu 2025 - Elaboración propia.

Este patrón sectorial guarda plena correspondencia con la jerarquía del grupo ocupacional (grupo1), donde las ocupaciones de dirección y alta calificación - Fuerzas Armadas (100.00%), Personal directivo de la administración pública y empresas (99.37%), Empleados de oficina (96.73%), Profesionales científicos e intelectuales (92.42%,) y Técnicos de nivel medio (90.75%) - operan casi exclusivamente en la formalidad. Por el contrario, los trabajadores calificados agropecuarios y pesqueros (grupo1 = 6) registran un 83.74% de informalidad (21,368 de 25,516) y los trabajadores no calificados en ocupaciones elementales (grupo1 = 9) alcanzan un 74.71% de informalidad (22,627 de 30,287); en conjunto, estos dos únicos grupos ocupacionales concentran el 62.16% de toda la población ocupada informal de la muestra.

6. Modelado Predictivo (Machine Learning)

Una vez caracterizada la distribución empírica de la muestra mediante el Análisis Exploratorio de Datos, se procedió a realizar la fase de modelado predictivo supervisado. El objetivo técnico de esta etapa consiste en entrenar y contrastar distintas arquitecturas algorítmicas capaces de aprender los patrones estructurales subyacentes en las diez variables predictoras (X) para estimar con alta precisión la probabilidad de pertenencia de un trabajador al sector formal de la economía (Y = *target_formal*).

6.1. Preprocesamiento y partición de datos

Un requisito fundamental en el diseño de experimentos de Machine Learning es garantizar la capacidad de generalización de los modelos ante datos no observados previamente, evitando el fenómeno de fuga de información o contaminación cruzada (Data Leakage). Este sesgo ocurre cuando información estadística del conjunto de evaluación (como medias, desviaciones estándar o categorías) se filtra de manera inadvertida durante la fase de entrenamiento, inflando artificialmente las métricas de desempeño.

Para neutralizar este riesgo metodológico, la matriz analítica limpia de 154,330 observaciones se dividió de forma previa a cualquier transformación matemática mediante la función train_test_split de la biblioteca scikit-learn, aplicando un esquema de partición estratificada en proporción 80/20:

- Conjunto de Entrenamiento (80%): Conformado por 123,464 registros, utilizado exclusivamente para ajustar los parámetros de preprocesamiento (fit_transform) y entrenar los pesos internos de los algoritmos clasificadores.
- Conjunto de Prueba (20%): Compuesto por 30,866 registros completamente aislados del proceso de aprendizaje, reservados para evaluar de forma imparcial el poder predictivo real de cada modelo.

El uso del parámetro de estratificación (stratify=y) aseguró que tanto la submuestra de entrenamiento como la de prueba conservaran exactamente la misma distribución de clases observada en la muestra nacional (54.14% de trabajadores formales y 45.86% de informales), garantizando además la reproducibilidad matemática del experimento mediante la fijación de una semilla aleatoria (random_state=42).

6.2. Ingeniería de características y Transformación Matricial

Dado que los algoritmos de clasificación operan sobre espacios vectoriales numéricos, la presencia simultánea de variables continuas en distintas escalas y variables categóricas codificadas con etiquetas numéricas nominales exige un flujo de transformación diferenciado. Si las variables categóricas de la ENEMDU (como rama1 con 21 secciones o p06 con 6 estados civiles) se introdujeran directamente en su codificación original, los algoritmos asumirían erróneamente una jerarquía métrica o distancia artificial entre categorías.

Para resolver esto de forma automatizada y libre de fugas de datos, se implementó un objeto ColumnTransformer que aplica dos tuberías paralelas de ingeniería de características:

a) Estandarización de Variables Numéricas Continuas (StandardScaler): Aplicada sobre las variables de Edad (p03) y Horas Semanales de Trabajo (p24). Cada observación se transforma mediante la puntuación estándar:

$$z = \frac{x - u}{\sigma}$$

donde u es la media muestral y σ la desviación estándar calculadas exclusivamente sobre el conjunto de entrenamiento. Este escalamiento centra ambas variables en media cero y varianza unitaria, evitando que la magnitud absoluta de la edad (rango de 15 a 98) o de las horas (rango de 1 a 124) distorsione la convergencia de los optimizadores lineales.

b) Codificación Binaria de Variables Categóricas (OneHotEncoder): Aplicada sobre las 8 variables categóricas del estudio: Sexo (p02), Área (area), Estado Civil (p06), Nivel de Instrucción (nnivins), Categoría de Ocupación (p42), Tamaño del Establecimiento (p47a), Rama de Actividad (rama1) y Grupo Ocupacional (grupo1). Para eliminar la multicolinealidad perfecta (conocida en econometría como la trampa de las variables ficticias o dummy), se configuró el parámetro drop='first', suprimiendo la primera categoría de referencia en cada variable.

Tabla 2: Transformación de variables en matrices

Tipo de Variable	Variables Originales (Códigos INEC)	Técnica Aplicada	Categorías Totales	Columnas Resultantes en la Matriz
Numéricas Continuas	p03, p24	StandardScaler (Z-score)	N/A (Continuas)	2
Categóricas Binarias	p02 (2), area (2), p47a (2)	OneHotEncoder(drop='first')	6 categorías (2+2+2)	3 (1+1+1)
Categóricas Politómicas	p06 (6), nnivins (5), p42 (9), grupo1 (10), rama1 (21)	OneHotEncoder(drop='first')	51 categorías (6+5+9+10+21)	46 (5+4+8+9+20)
Total Matriz Transformada	10 variables predictoras originales	ColumnTransformer	—	51 columnas matemáticas

Como resultado de esta arquitectura de preprocesamiento, las 10 variables originales se expandieron geométricamente hacia una matriz dispersa de 51 características matemáticas sobre la cual se ejecutó el entrenamiento de los modelos.

6.3. Algoritmos de Clasificación Seleccionados y Configuración Técnica

Con el propósito de contrastar empíricamente el desempeño de distintas familias algorítmicas sobre la matriz de 123,464 x 51 datos de entrenamiento, se seleccionaron y configuraron tres modelos supervisados representativos de los paradigmas lineal y no lineal de ensamble:

a) Regresión Logística (Modelo Base Paramétrico)

Se implementó como línea base de referencia mediante la clase LogisticRegression (max_iter=1000, random_state=42). A nivel matemático, este modelo estima la probabilidad condicional de que un trabajador i pertenezca al sector formal $(y_i = 1)$ dado su vector de $p = 51$ características transformadas $x_i = x_{i1}, x_{i2}, \dots, x_{ip}$), aplicando la función logística o sigmoide:

$$P(y_1 = 1 | x_1) = \rho_i = \frac{1}{1 + e^{-(B_0 + \sum_{j=1}^{P} B_{jxij})}}$$

Donde B_0 representa el intercepto y B_j los coeficientes asociados a cada variable predictora. El entrenamiento del algoritmo consiste en hallar el vector de parámetros B que minimiza la función de pérdida de Entropía Cruzada Binaria (Log-Loss) con regularización L_2 sobre las $N = 123.464$ observaciones de entrenamiento:

$$L(B) = -\frac{1}{N}\sum_{i=1}^{N}[y_1 \ln(\rho_i) + (1 - y_i)\ln(1 - \rho_i)] + \frac{\lambda}{2}\sum_{j=1}^{p} B_j^2$$

La ampliación del hiperparámetro de iteraciones a max_iter=1000 garantizó la convergencia numérica del optimizador cuasi-Newton (L-BFGS) frente a la alta dimensionalidad de la matriz dispersa.

Al estimar una frontera de decisión lineal en el espacio logarítmico de probabilidades (log-odds), este modelo permite evaluar qué proporción de la formalidad laboral puede explicarse mediante efectos aditivos simples de las 51 características sin considerar interacciones complejas. La ampliación del límite de iteraciones a 1,000 garantizó la convergencia numérica del optimizador L-BFGS ante la alta dimensionalidad de las variables binarizadas.

b) **Random Forest / Bosque Aleatorio (Ensamble No Lineal por *Bagging*)**

Se entrenó mediante la clase RandomForestClassifier (n_estimators=100, random_state=42, n_jobs=-1). Este algoritmo construye en paralelo B = 100 árboles de decisión independientes $\{T_1(X), T_2(X), \dots, T_B(X)\}$ sobre muestras generadas con reemplazo (*bootstrap*).

Durante la construcción de cada árbol, la selección del punto de corte óptimo en cada nodo interno se determina minimizando el Índice de Impureza de Gini sobre un subconjunto aleatorio de variables $\left(m = \left|\sqrt{51}\right| = 7\ variables\ por\ nodo\right)$.

$$G = \sum_{k\epsilon\{0,1\}} Pmk(1 - Pmk) = 2Pm_1(1 - Pm_1)$$

donde Pm_1 es la proporción de trabajadores formales en el nodo m. Una vez entrenados los B árboles, la probabilidad estimada final del bosque se obtiene mediante el promedio de las predicciones individuales (*Bagging*), reduciendo la varianza del estimador:

$$P_{RF}(Y_1 = 1 \mid X_1) = \frac{1}{B}\sum_{b=1}^{B} T_b(X_i)$$

c) Gradient Boosting Classifier (Ensamble No Lineal por Boosting)

Se implementó a través de la clase GradientBoostingClassifier (n_estimators=100, learning_rate=0.1, max_depth=3, random_state=42). A diferencia del bosque aleatorio, esta arquitectura construye un modelo aditivo secuencial en M = 100 etapas, donde en cada iteración *m* se incorpora un nuevo árbol de regresión débil $h_m(X)$ de profundidad restringida (max_depth=3):

$$F_m(X_i) = F_{m-1}(X_i) + v * h_m(X_i)$$

En esta expresión, $F_{m-1}(X_i)$ es el modelo acumulado en la etapa previa y $v = 0.1$ corresponde a la tasa de aprendizaje (learning_rate), la cual actúa como factor de regularización para prevenir el sobreajuste. Cada nuevo árbol $h_m(X_i)$ no se entrena sobre la variable original Y, sino que se ajusta directamente sobre los **pseudo-residuos** (r_{im}), definidos como el gradiente negativo de la función de pérdida logarítmica (*deviance*) evaluada en el paso anterior:

$$r_{im} = -\left[\frac{\partial L(y_1, F(X_i))}{\partial F(X_i)}\right]_{F(X)=F_{m-1}(X)} = y_i - \frac{1}{1+e^{-Fm-1(X_i)}}$$

Esta optimización iterativa por gradiente descendente en el espacio de funciones permite que cada árbol sucesivo se especialice en corregir los casos de clasificación más complejos (como trabajadores en empresas pequeñas, pero con alta escolaridad), capturando interacciones no lineales anidadas con alta precisión.

7. Evaluación de Resultados

Una vez concluido el entrenamiento de los tres algoritmos sobre la submuestra de aprendizaje (123,464 registros), se procedió a evaluar su capacidad de generalización sobre el conjunto de prueba aislado (n= 30,866 observaciones, compuesto por 16,711 trabajadores formales reales y 14,155 trabajadores informales reales). Esta validación externa permite cuantificar con objetividad el desempeño predictivo de cada arquitectura frente a datos no observados previamente.

7.1. Métricas de Desempeño Comparativas

Para realizar una evaluación integral que no dependa de un único indicador, se calcularon cinco métricas estándar de clasificación supervisada:

- Exactitud Global (Accuracy): Proporción total de predicciones correctas (tanto formales como informales) sobre el total de observaciones evaluadas.
- Precisión (Precision): Proporción de trabajadores predichos como formales que realmente pertenecen al sector formal, penalizando la presencia de falsos positivos.
- Sensibilidad (Recall o Tasa de Verdaderos Positivos): Capacidad del algoritmo para detectar correctamente a la totalidad de los trabajadores formales reales dentro de la muestra, penalizando los falsos negativos.
- Puntuación F1 (F1-Score): Media armónica entre la Precisión y la Sensibilidad, la cual resume el equilibrio predictivo de cada clase en un solo indicador.
- Área Bajo la Curva ROC (ROC-AUC): Medida de discriminación probabilística global que evalúa la capacidad del modelo para separar correctamente ambas clases a través de todos los umbrales de probabilidad posibles (0 a 1).

Tabla 3: Comparación de resultados por modelo

Algoritmo / Modelo	Exactitud Global Accurac	Precisión (Formal = 1)	Sensibilidad / Recall (Formal = 1)	F1-Score (Formal = 1)	Precisión (Informal = 0)	Sensibilidad / Recall (Informal = 0)	F1-Score (Informal = 0)	F1-Score Ponderado	ROC-AUC
Regresión Logística (Lineal Base)	86,59%	88,75%	86,16%	87,44%	84,20%	87,11%	85,63%	86,61%	9,415

Random Forest (Bagging)	85,30%	86,49%	86,33%	86,41%	83,90%	84,08%	83,99%	85,30%	9,280
Gradient Boosting (Modelo Campeón)	87,00%	88,32%	87,57%	87,94%	85,47%	86,33%	85,90%	87,00%	9,450

El análisis comparativo de las métricas evidencia que los tres algoritmos superan el umbral del 85% de exactitud global, confirmando que las diez variables predictoras seleccionadas contienen una señal estadística altamente informativa sobre la estructura laboral ecuatoriana,

Al contrastar el rendimiento por algoritmo, el clasificador Gradient Boosting se posiciona en el primer lugar al alcanzar una Exactitud Global del 87%, el mayor F1-Score para la clase formal (87,94%) y para la clase informal (85,90%), así como una capacidad de discriminación probabilística sobresaliente reflejada en un ROC-AUC de 0,9450,

En segundo lugar, se ubica la Regresión Logística, la cual logra una exactitud del 86,59% y destaca por obtener la precisión puntual más alta en la clase formal (88,75%) y la mayor sensibilidad en la clase informal (87,11%), aunque cede terreno en la sensibilidad de detección formal (86,16% frente al 87,57% de Gradient Boosting), Finalmente, el modelo Random Forest registra el desempeño relativo más bajo del grupo con una exactitud del 85,30% y un F1-Score ponderado de 85,30%, debido a que la construcción de árboles no restringidos en un espacio disperso de 51 variables binarizadas genera una ligera sobre-partición en combinaciones demográficas específicas,

7.2. Matrices de Confusión y Evaluación de Tipos de Error

Para desagregar el comportamiento interno de los clasificadores más allá de los promedios porcentuales, se analizaron las Matrices de Confusión sobre los 30,866 individuos del conjunto de prueba, contrastando la etiqueta real observada en la ENEMDU frente a la predicción emitida por cada modelo.

Tabla 4: Matriz de confusión.

Algoritmo / Modelo	Verdaderos Negativos (VN: Informal bien clasificado)	Falsos Positivos (FP: Error Tipo I)	Falsos Negativos (FN: Error Tipo II)	Verdaderos Positivos (VP: Formal bien clasificado)	Total Aciertos (VP + VN)	Total Errores (FP + FN)
Regresión Logística	12.330	1.825	2.313	14.398	26.728 (86,6%)	4.138 (13,4%)
Random Forest	11.902	2.253	2.284	14.427	26.329 (85,3%)	4.537 (14,7%)
Gradient Boosting (Modelo Campeón)	12.220	1.935	2.078	14.633	26.853 (87%)	4.013 (13%)

La inspección detallada de las celdas de las tres matrices permite extraer hallazgos fundamentales sobre la naturaleza de los aciertos y los errores de clasificación:

a) Maximización de Verdaderos Positivos (VP) y Verdaderos Negativos (VN): El algoritmo Gradient Boosting logra clasificar correctamente el estado laboral de 26.853 trabajadores de los 30,866 evaluados (superando en 125 aciertos netos a la Regresión Logística y en 524 aciertos al Random Forest). Específicamente, alcanza el mayor volumen de Verdaderos Positivos al identificar con exactitud a 14.633 trabajadores formales (de 16.711 reales), manteniendo simultáneamente una alta detección de Verdaderos Negativos con 12.220 trabajadores informales correctamente clasificados (de 14.155 reales).
b) Análisis del Error Tipo I — Falsos Positivos (FP): Corresponde a individuos que en la realidad pertenecen al sector informal (0), pero que el algoritmo predice como formales (1). Este error se presenta típicamente en trabajadores con perfiles atípicos: por ejemplo, profesionales con educación superior (nnivins = 5) en zonas urbanas que operan por cuenta propia sin RUC registrado. La Regresión Logística registra el menor volumen de Falsos Positivos (1.825 casos), seguida muy de cerca por Gradient Boosting (1.935 casos), mientras que Random Forest eleva este error hasta los 2.253 casos.
c) Análisis del Error Tipo II — Falsos Negativos (FN): Representa a trabajadores que son formalmente ocupados en la realidad (1), pero que el modelo clasifica erróneamente como informales (0) —tales como trabajadores con educación básica o agropecuarios que sí laboran bajo relación de dependencia formal en empresas registradas—. En este rubro crítico, Gradient Boosting demuestra su mayor superioridad técnica, reduciendo los Falsos Negativos a 2.078 casos, frente a los 2.284 de Random Forest y los 2.313 de la Regresión Logística.

7.3. Selección del Modelo Óptimo: Justificación Técnica

Con base en la evidencia empírica recopilada en las métricas globales y en la descomposición matricial de errores, se selecciona oficialmente al algoritmo Gradient Boosting Classifier como el modelo ganador del estudio. Su elección se fundamenta en tres criterios técnicos y metodológicos:

a) Superioridad en Discriminación Probabilística (ROC-AUC = 0,9450) y Exactitud (87,00%): En problemas de clasificación socioeconómica, alcanzar un área bajo la curva ROC de 0,9450 indica una capacidad de separación excelente (superior al umbral de 0,90 considerado de alto rendimiento en la literatura de Machine Learning). Esto significa que, si se selecciona aleatoriamente a un trabajador formal y a uno informal de la muestra ecuatoriana, el modelo Gradient Boosting asignará una probabilidad de formalidad más alta al trabajador formal en el 94,50% de las ocasiones.
b) Equilibrio Óptimo entre Errores Tipo I y Tipo II (Máximo F1-Score): Mientras que la Regresión Logística adopta una frontera lineal conservadora que sacrifica la detección de trabajadores formales (generando 2.313 Falsos Negativos), Gradient Boosting corrige secuencialmente estos residuos mediante árboles de profundidad controlada (max_depth=3), logrando reducir el total general de errores al mínimo del experimento (4.013 errores totales, equivalente a solo el 13,00% de la muestra de prueba) y maximizando el F1-Score en ambas clases (87,94% en formales y 85,90% en informales).

c) Captura de Interacciones Estructurales No Lineales sin Sobreajuste (Overfitting): A diferencia de Random Forest —cuyos árboles profundos independientes sufrieron una caída de rendimiento al fragmentar las 51 columnas One-Hot (85,30% de exactitud)—, la arquitectura de potenciación del gradiente (boosting) con tasa de aprendizaje regularizada ($\nu = 0,1$) demostró ser la estructura matemática idónea para modelar las reglas condicionales anidadas del mercado laboral ecuatoriano.

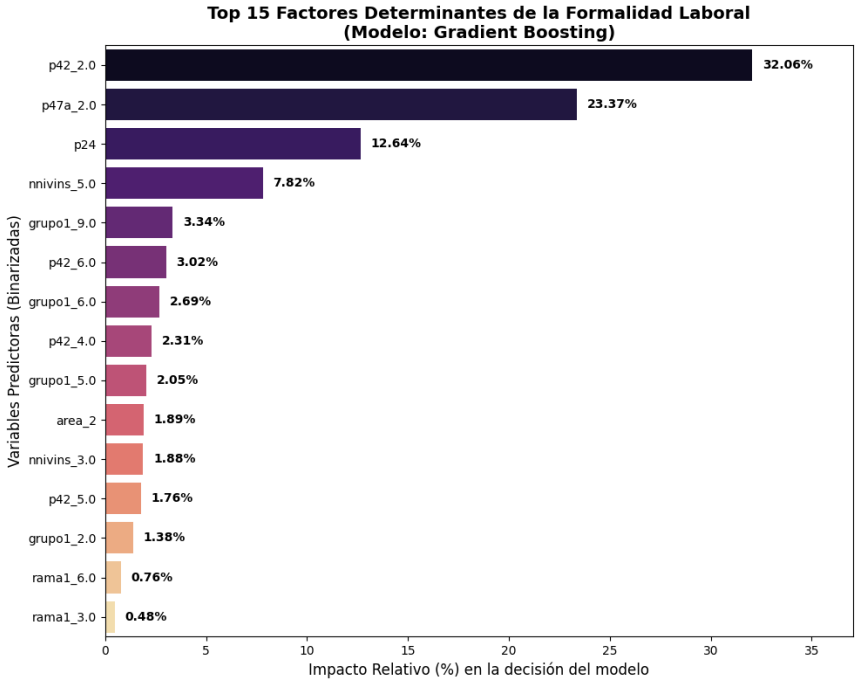
8. Conclusiones y Factores Determinantes

La etapa final de este estudio trasciende la validación estadística del rendimiento predictivo para adentrarse en la interpretabilidad económica del modelo ganador (Gradient Boosting Classifier, con una exactitud del 87% y un ROC-AUC de 0,9450). Al abrir la estructura algorítmica del ensamble, es posible cuantificar el peso específico que cada característica ejerce sobre la probabilidad de que un trabajador ecuatoriano pertenezca al sector formal, transformando los resultados matemáticos en hallazgos estratégicos.

8.1. Importancia de Variables: Análisis del Top 15 de Factores Determinantes

En los modelos de ensamble basados en árboles de decisión como Gradient Boosting, la importancia relativa de una variable se calcula midiendo la reducción total de la impureza del criterio de partición (criterio de Friedman MSE sobre los pseudo-residuos) aportada por cada una de las 51 características matemáticas a lo largo de los 100 árboles secuenciales, normalizando la suma total al 100%.

El examen de las 15 variables con mayor poder discriminante revela una concentración altamente pronunciada: únicamente los cuatro primeros factores explican en conjunto el 75,89% de toda la capacidad predictiva del modelo, mientras que las 11 variables subsiguientes del Top 15 actúan como moduladores sectoriales, ocupacionales y territoriales.



a) Categoría de Ocupación: Empleado Privado (p42_2 - 32,06% de importancia relativa): Se consolida como el predictor individual más determinante de todo el mercado laboral ecuatoriano, concentrando casi un tercio del logro de pureza del modelo. Estar inserto bajo una relación salarial en el sector privado corporativo separa de manera inmediata al trabajador informal, constituyendo la frontera primaria de clasificación (donde el 90,81% de sus integrantes son formales).
b) Tamaño del Establecimiento: 100 y más trabajadores (p47a_2 - 23,37% de importancia relativa): Ocupa el segundo lugar en la jerarquía algorítmica. Dado que en la muestra analizada el 100% de los 29.320 trabajadores pertenecientes a la gran empresa operan en la formalidad, el algoritmo utiliza este nodo como una regla de decisión pura (impureza cero): si el trabajador labora en un establecimiento de gran escala, el modelo le asigna automáticamente la condición de formalidad.
c) Horas de Trabajo Semanal (p24 - 12,64% de importancia relativa): Es la variable numérica continua de mayor peso en el modelo. El algoritmo captura la brecha estructural entre la jornada legal estandarizada del sector formal (mediana exacta de 40 horas y media de 39,92 horas) frente a la dispersión e insuficiencia horaria del sector informal (mediana de 30 horas y media de 29,64 horas).
d) Nivel de Instrucción: Educación Superior (nnivins_5 - 7,82% de importancia relativa): Representa el factor principal de dotación de capital humano. Contar con formación técnica o universitaria incrementa sustancialmente el gradiente de probabilidad hacia la formalidad (tasa descriptiva del 83,89% de formalidad en este grupo), permitiendo al modelo clasificar correctamente incluso a profesionales que laboran en empresas de menos de 100 trabajadores.
e) Bloque Estructural Complementario del Top 15 (Posiciones 5 a 15 — ~20,5% acumulado): El resto de las quince características más relevantes está dominado por categorías que perfilan los extremos ocupacionales y territoriales del país:
   - Modalidades de inserción empresarial y autoempleo (p42): La condición de Cuenta Propia (p42_6), Patrono (p42_5) y Jornalero o Peón (p42_4) operan como diferenciadores clave dentro de las unidades de menos de 100 trabajadores, distinguiendo al empleador formalizado (80,9% formal) del cuentapropista (71,8% informal) y del jornalero (88% informal).
   - Frontera educativa secundaria: El nivel de Educación Media/Bachillerato (nnivins_4) y la Educación Básica (nnivins_3) actúan como umbrales intermedios de segmentación para trabajadores operativos.
   - Especialización ocupacional y sectorial (grupo1 y rama1): Destacan dentro del Top 15 los grupos de Trabajadores de los servicios y comerciantes (grupo1_7), Profesionales científicos e intelectuales (grupo1_5) y Trabajadores calificados agropecuarios (grupo1_6), en conjunto con ramas de alto volumen como Comercio (rama1_G), Industrias manufactureras (rama1_C) y Enseñanza (rama1_P).
   - Factor territorial y ciclo de vida (area y p03): El residir en el Área Rural (area_2) y la Edad continua (p03) cierran el grupo de las 15 variables principales, ajustando las probabilidades en zonas agrícolas y en los extremos de la pirámide etaria (jóvenes y adultos mayores).

8.2. Hallazgos Económicos y Estructurales: La Primacía de la Matriz Productiva y el Capital Humano

La evidencia empírica emanada del modelo campeón permite establecer una conclusión económica central para el Ecuador: la formalidad laboral no es un atributo determinado por las características demográficas intrínsecas del individuo, sino el resultado directo de la heterogeneidad estructural del aparato productivo y de la acumulación de capital humano.

Este hallazgo se sustenta en tres pilares analíticos:

a) Hegemonía de la Demanda Productiva (Estructura Empresarial): La combinación entre la categoría ocupacional privada (p42_2) y la escala de gran empresa (p47a_2) concentra por sí sola el 55,43% del poder explicativo del algoritmo. Esto confirma la tesis estructuralista de la CEPAL y la OIT revisada en el marco teórico, la cual afirma que la capacidad de generar empleo formal depende fundamentalmente de la existencia de unidades económicas modernas con escala financiera, administrativa y tecnológica suficiente para asumir los costos regulatorios y de seguridad social. La informalidad en el Ecuador (que abarca el 45,86% de la muestra analizada) se refugia en su totalidad en establecimientos de menos de 100 trabajadores y se alimenta en un 58,29% del trabajo por cuenta propia de baja productividad.
b) El Capital Humano incide en la Movilidad Sectorial: Cuando un trabajador no se encuentra empleado en una corporación de más de 100 trabajadores, el predictor que define su transición hacia la formalidad es la Educación Superior en sinergia con el cumplimiento de jornadas laborales completas. Mientras que un trabajador con educación básica tiene apenas un 27,75% de probabilidad de ser formal, mientras que alcanzar un título de tercer o cuarto nivel eleva dicha tasa al 83,89%.
c) Neutralidad Relativa de los Factores Puramente Demográficos: Uno de los descubrimientos más reveladores del aprendizaje automático es la relegación de las variables demográficas (como el Sexo y el Estado Civil) hacia los últimos lugares de importancia en las 51 columnas evaluadas. Tal como se demostró en el análisis descriptivo -donde las mujeres ocupadas registraron un 54,71% de formalidad frente a un 53,71% en los hombres-, una vez que el algoritmo controla por nivel educativo, tamaño de empresa y categoría ocupacional, las variables de género o estado conyugal pierden relevancia estadística como determinantes de la formalidad.

8.3. Reflexión Metodológica: El Valor de Integrar SQL y Machine Learning

Desde la perspectiva de la ingeniería de datos y la econometría aplicada, el desarrollo de este estudio demuestra las ventajas competitivas de adoptar una arquitectura computacional moderna que articule motores relacionales (SQLite) con algoritmos no lineales de Machine Learning (scikit-learn) para el procesamiento de encuestas nacionales de hogares como la ENEMDU:

- Gobernanza, Integridad y Reproducibilidad mediante SQL: En la investigación económica tradicional, el manejo directo de microdatos crudos en hojas de cálculo o scripts aislados suele derivar en inconsistencias de filtrado y alto consumo de memoria. La implementación de un

proceso ETL riguroso que deposita las 154.330 observaciones limpias en una base de datos relacional (enemdu_2025.db) garantizó una fuente única. La ejecución de consultas estructuradas permitió desacoplar la ingeniería de datos del modelado matemático, asegurando una trazabilidad auditable y tiempos de lectura inmediatos.

- Superación de los Límites Lineales sin sobreajuste: La comparativa algorítmica evidenció que, si bien la econometría paramétrica clásica (representada por la Regresión Logística, con 86,59% de exactitud) ofrece una aproximación inicial sólida, los métodos de ensamble secuencial como Gradient Boosting (87% de exactitud y 0,9450 de ROC-AUC) logran capturar interacciones anidadas de orden superior (reduciendo los Falsos Negativos de 2.313 a 2.078 casos) sin requerir que el investigador especifique manualmente términos multiplicativos entre las 51 variables binarizadas.
- Potencial de Despliegue en Políticas Basadas en Evidencia: Finalmente, este flujo de trabajo integrado transforma una encuesta estática en una herramienta predictiva dinámica. Un modelo entrenado y validado bajo este estándar de ingeniería permite a las instituciones públicas, centros de pensamiento y organismos multilaterales simular escenarios de política económica, identificar perfiles de vulnerabilidad laboral con un 94,5% de discriminación probabilística y focalizar recursos de formalización con precisión microanalítica en el territorio ecuatoriano.

9. Bibliografía

Abramo, L. (31 de agosto de 2021). *Informalidad laboral y la matriz de la desigualdad social.* Obtenido de Políticas para su abordaje: https://www.cepal.org/sites/default/files/events/files/01_lais_abramo.pdf

Borrastero, C., Viganó, A., & Gómez, M. C. (2022). Heterogeneidad Estructural como Restricción al Desarrollo Productivo y las Mejoras Salariales Sustentables en la Industria Argentina. Un Análisis en Perspectiva Histórica. *Red Nacional de Investigadores en Economía*, 1-44. Obtenido de https://rednie.eco.unc.edu.ar/files/DT/171.pdf

INEC, I. N. (diciembre de 2025). *Indicadores Laborales.* Obtenido de Encuesta Nacional de Empleo, Desempleo y Subempleo (ENEMDU): https://www.ecuadorencifras.gob.ec/documentos/web-inec/EMPLEO/2025/Diciembre_2025/202512_MercadoLaboral.pdf

Instituto Nacional de Estadísticas y Censos, I. (2015). *Actualización de metodología.* Obtenido de Empleo en el sector informal: https://www.ecuadorencifras.gob.ec/documentos/web-inec/Estudios%20e%20Investigaciones/Trabajo_empleo/4.%20REM-Actualizacion_metodologica_empleo_informal.pdf

Mendoza, J., Macías, L., Morales, J., & Cedeño, L. (2024). Modelos de aprendizaje automático: aplicación y eficiencia. *Revista Científica de Informática ENCRIPTAR - ISSN: 2737-6389.*, noviembre.

Organización Internacional del Trabajo, O. (septiembre de 2021). *Teoría del cambio: Formalización empresarial para el trabajo decente.* Obtenido de https://www.ilo.org/es/media/7851/download

Organización Internacional del Trabajo, O. (18 de febrero de 2021). *Transición de la economía informala la economía formal.* Obtenido de https://www.ilo.org/es/publications/transicion-de-la-economia-informal-la-economia-formal-teoria-del-cambio

Portilla Cartuche, A. (marzo de 2026). *Implementación de Modelos Predictivos para la Gestión del Proceso de Polinización y Germinación de Semillas en la Empresa Ecuagenera.* Obtenido de https://repositorio.uide.edu.ec/bitstream/37000/9246/1/UIDE-L-TTI-2026-16.pdf

Solon, G., Haider, S., & Wooldridge, J. (febrero de 2013). *National Bureau of Economic Research.* Obtenido de https://www.nber.org/system/files/working_papers/w18859/w18859.pdf

Tokman, V. (2007). Informalidad, inseguridad y cohesión social en América Latina. *Revista Internacional del Trabajo, vol. 126*, 1-35.

Valdiviezo, H., & Aguiar, M. (julio de 2026). *Aplicación de modelos de aprendizaje automático para el cálculo de horas de trabajo no remunerado en las Cuentas Satélites del Trabajo No Remunerado.* Obtenido de https://www.ecuadorencifras.gob.ec/documentos/web-inec/Bibliotecas/Libros/cuadernos_trabajo/Aplicacion_modelo_aprendizaje_calculo_TNR.pdf

10. Repositorio de código:

- https://github.com/mendietasaul/clasificacion-Formalidad-Laboral-ENEMDU-2025